

APRENDIZADO NÃO SUPERVISIONADO

APRESENTAÇÃO DA DISCIPLINA



Quem sou eu?



Thomas Paula

✉️ tsp.thomas@gmail.com

🐦 [@tsp_thomas](https://twitter.com/tsp_thomas)



PUCRS

Pontifícia Universidade Católica
do Rio Grande do Sul

Machine Learning
PORTO ALEGRE



E vocês, quem são? :)

- ✗ Qual seu nome?
- ✗ Com o que você trabalha/o que estuda?
- ✗ Tem experiência com Machine Learning?
- ✗ Por que procuraram a especialização? Qual o objetivo?
- ✗ Quais suas expectativas para a disciplina?



Tópicos da Disciplina

- ✗ Introdução ao Aprendizado Não Supervisionado
- ✗ Agrupamento de Dados (Clustering)
- ✗ Redução de Dimensionalidade
- ✗ Modelos Generativos



Trabalhos

- ✗ Vamos ter algumas implementações a serem entregues
- ✗ Será dado tempo em aula para trabalhar e tirar dúvidas
- ✗ Todos os aspectos serão considerados
 - ✗ Código e documentação
 - ✗ Experimentos realizados e conclusões
 - ✗ Entrega na data combinada
- ✗ Entrega via Github (repositório acessível publicamente) ou email



Calendário (sujeito a alterações)

09/01/19	Introdução ao Aprendizado Não Supervisionado
10/01/19	Agrupamento de Dados
15/01/19	Agrupamento de Dados
16/01/19	Agrupamento de Dados
17/01/19	Redução de Dimensionalidade
22/01/19	Modelos Generativos e Fechamento da Disciplina



Machine Learning



what society thinks I
do

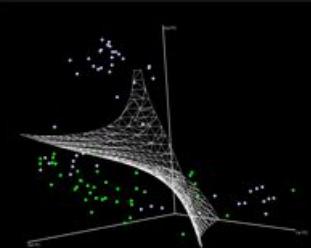


what my friends think
I do



what my parents think
I do

$$\begin{aligned}L_t &= \frac{1}{2}\|\mathbf{w}\|^2 - \sum_{i=1}^n \alpha_i y_i (\mathbf{x}_i \cdot \mathbf{w} + b) + \sum_{i=1}^n \alpha_i \\&\alpha_i \geq 0, \forall i \\&\mathbf{w} = \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i, \sum_{i=1}^n \alpha_i y_i = 0 \\&\nabla \hat{g}(\theta_t) = \frac{1}{n} \sum_{i=1}^n \nabla \ell(x_i, y_i; \theta_t) + \nabla r(\theta_t). \\&\theta_{t+1} = \theta_t - \eta_t \nabla \ell(x_{i(t)}, y_{i(t)}; \theta_t) - \eta_t \cdot \nabla r(\theta_t) \\&\mathbb{E}_{i(t)}[\ell(x_{i(t)}, y_{i(t)}; \theta_t)] = \frac{1}{n} \sum_i \ell(x_i, y_i; \theta_t).\end{aligned}$$



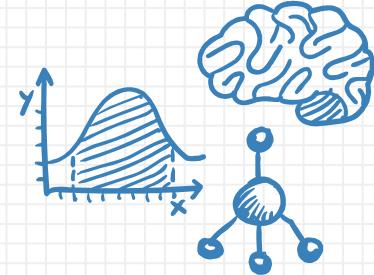
```
>>> from sklearn import svm
```

what other programmers
think I do

what I think I do

what I really do





INTRODUÇÃO AO APRENDIZADO NÃO SUPERVISIONADO



Agenda de Hoje

- ✗ Introdução
 - ✗ Recapitulando Aprendizado Supervisionado
 - ✗ Exemplos do estado-da-arte
- ✗ Aprendizado Não Supervisionado
 - ✗ Definições e exemplos
 - ✗ Exemplos do estado-da-arte



Introdução

Recapitulando Aprendizado Supervisionado



Aprendizado Supervisionado

- ✗ O que é Aprendizado Supervisionado?
- ✗ Quais algoritmos são exemplos de Aprendizado Supervisionado?
- ✗ Como podemos avaliar algoritmos de Aprendizado Supervisionado?
- ✗ O que é overfitting?
- ✗ Qual é o principal objetivo de Machine Learning?

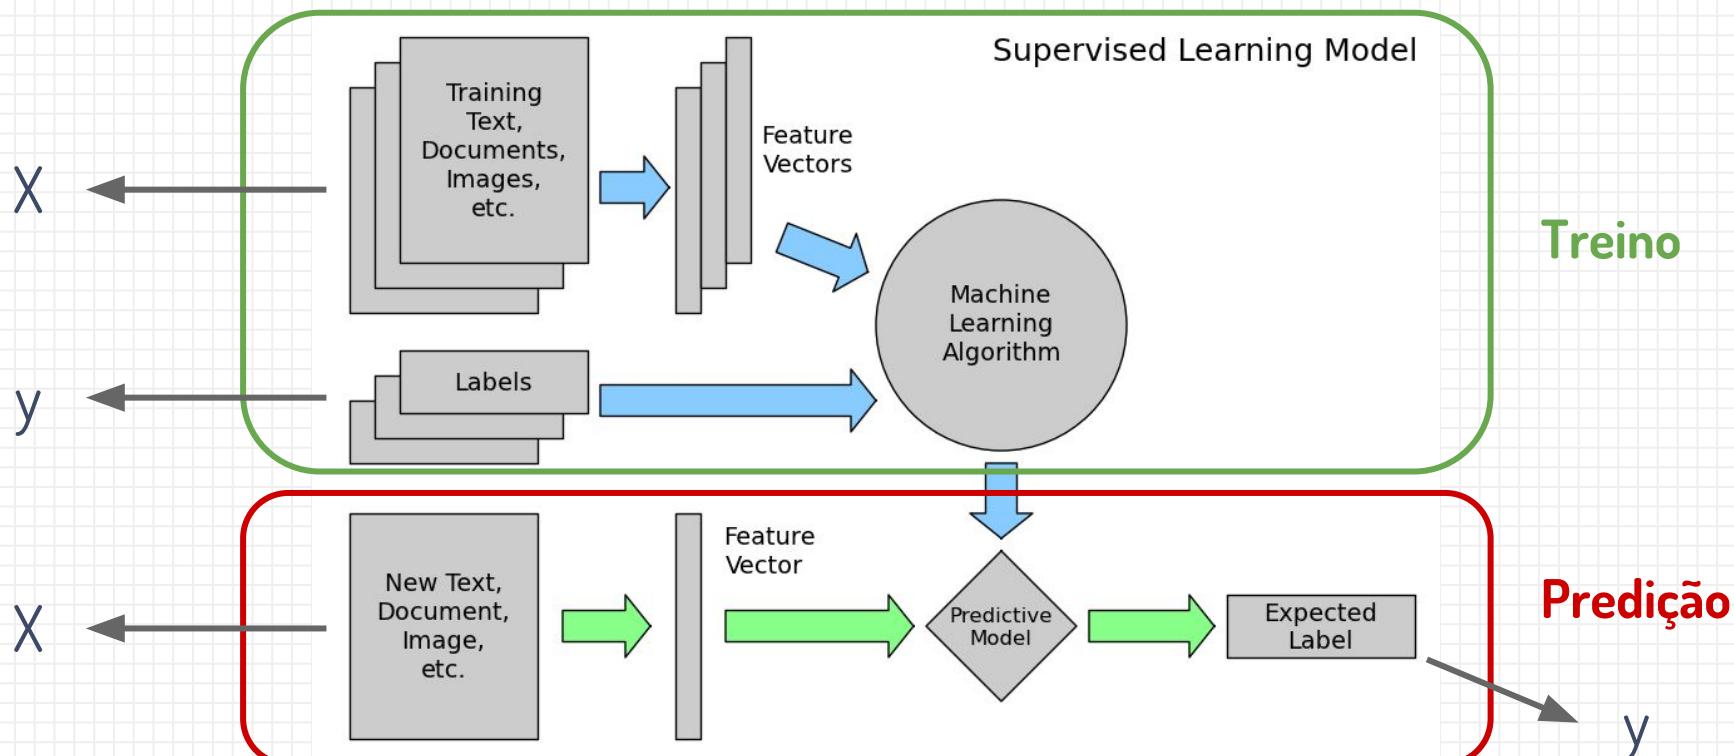


Aprendizado Supervisionado

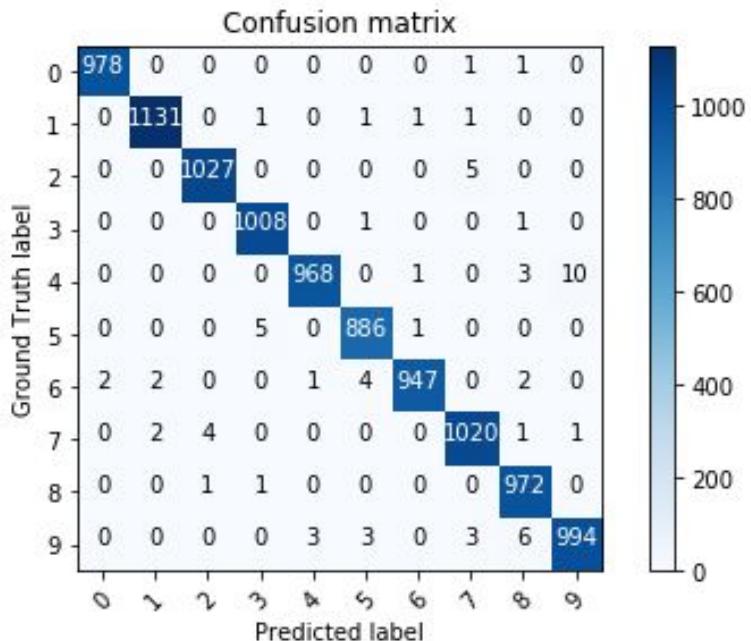
- ✗ Aprender mapeamento de uma entrada para uma saída
- ✗ Tem um “professor externo”
 - ✗ Respostas são fornecidas (dados rotulados)



Aprendizado Supervisionado



Como avaliar?



Aprendizado Supervisionado

Alguns exemplos do estado-da-arte



Semantic Segmentation

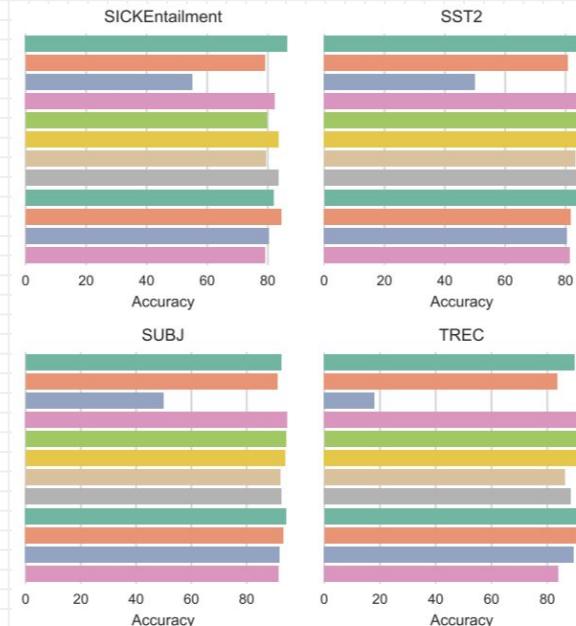


Fonte: He, Kaiming, et al. "Mask r-cnn." Computer Vision (ICCV), 2017 IEEE International Conference on. IEEE, 2017.



Natural Language Processing (NLP)

Dataset	Task	Example	Output
Customer Reviews (CR) [19]	Sentiment analysis of customer products' reviews	We tried it out Christmas night and it worked great .	Positive
Multi-Perspective Question and Answering (MPQA) [39]	Evaluation of opinion polarity	Don't want	Negative
Movie Reviews (MR) [31]	Sentiment analysis of movie reviews	Too slow for a younger crowd , too shallow for an older one .	Negative
Stanford Sentiment Analysis 2 (SST-2) [36]	Sentiment analysis with two classes: Negative and Positive	Audrey Tautou has a knack for picking roles that magnify her [...]	Positive
Stanford Sentiment Analysis 5 (SST-5) [36]	Sentiment analysis with 5 classes, that range from 0 (most negative) to 5 (most positive)	Nothing about this movie works	0
Subjectivity / Objectivity (SUBJ) [30]	Classify the sentence as Subjective or Objective	A movie that doesn't aim too high , but doesn't need to .	Subjective
Text REtrieval Conference (TREC) [38]	Question and answering	What are the twin cities ?	LOC:city



Fonte: Christian S. Perone, Roberto Silveira, and Thomas S. Paula. "Evaluation of sentence embeddings in downstream and linguistic probing tasks." arXiv preprint arXiv:1806.06259(2018).



Image Captioning



A woman is throwing a **frisbee** in a park.



A **dog** is standing on a hardwood floor.



A **stop** sign is on a road with a mountain in the background



A little **girl** sitting on a bed with a teddy bear.



A group of **people** sitting on a boat in the water.



A giraffe standing in a forest with **trees** in the background.

Fonte: LeCun, Yann, Yoshua Bengio, and Geoffrey Hinton. "Deep learning." *nature* 521.7553 (2015): 436.



Speech Recognition

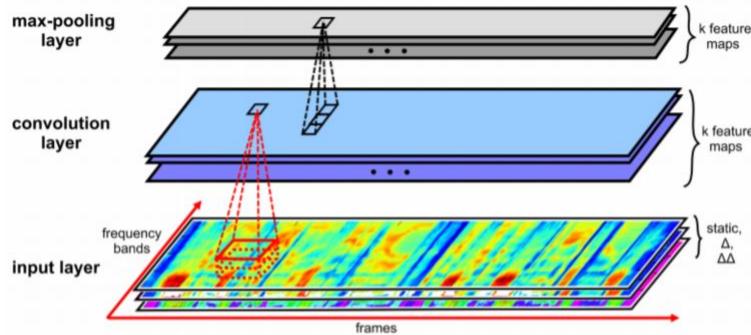


Figure 1: The convolution layer and max-pooling layer applied upon input features.

Model	NP	Dev PER	Test PER
BiLSTM-3L-250H [12]	3.8M	-	18.6%
BiLSTM-5L-250H [12]	6.8M	-	18.4%
TRANS-3L-250H [12]	4.3M	-	18.3%
CNN-(3,5)-10L-ReLU	4.3M	17.4%	19.3%
CNN-(3,5)-10L-PReLU	4.3M	17.2%	18.9%
CNN-(3,5)-6L-maxout	4.3M	18.7%	21.2%
CNN-(3,5)-8L-maxout	4.3M	17.7%	19.8%
CNN-(3,3)-10L-maxout	4.3M	18.4%	19.9%
CNN-(3,5)-10L-maxout	4.3M	16.7%	18.2%

Fonte: Zhang, Ying, et al. "Towards end-to-end speech recognition with deep convolutional neural networks." arXiv preprint arXiv:1701.02720 (2017).



Text Recognition



(a) ICDAR 2015



(b) ICDAR 2017 MLT

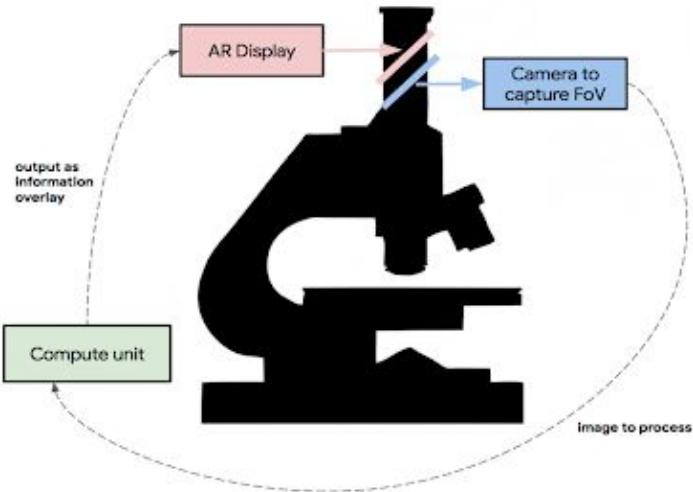


(c) ICDAR 2013

Fonte: Liu, Xuebo, et al. "FOTS: Fast Oriented Text Spotting with a Unified Network." Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018.



Cancer Detection

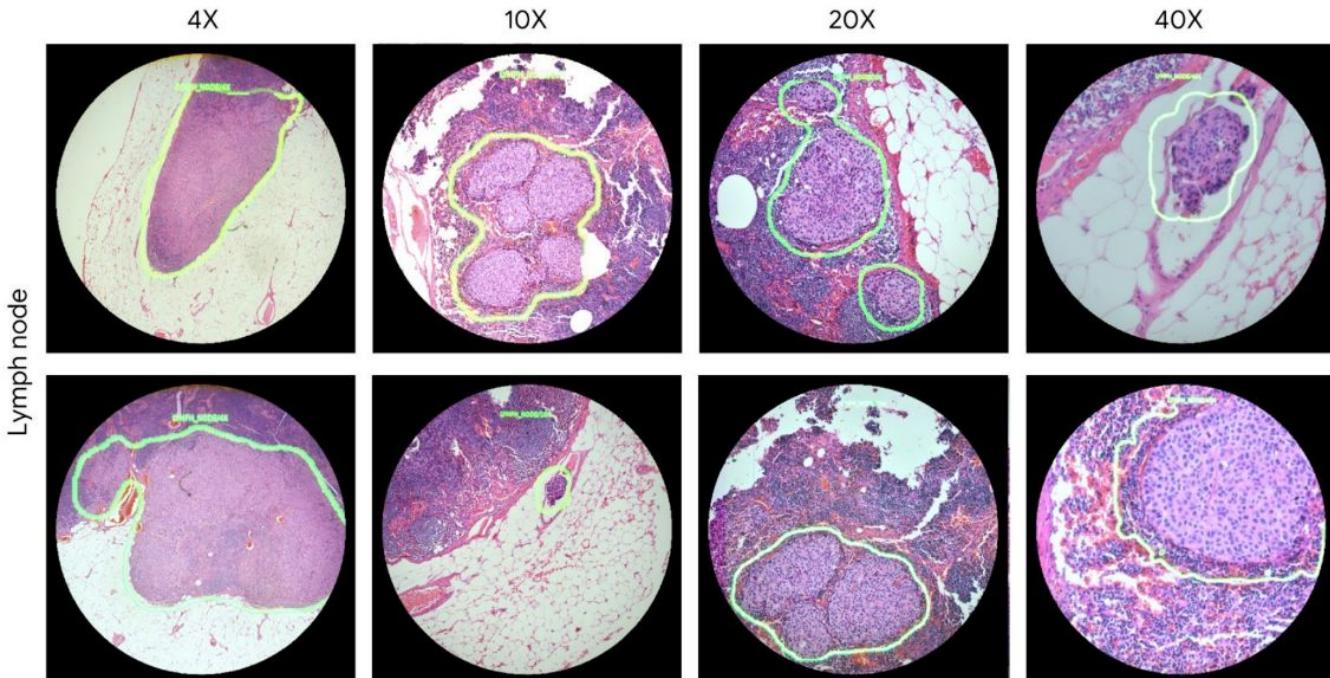


Research at Google

Fonte: An Augmented Reality Microscope, Google Research Blog, 2018.



Cancer Detection



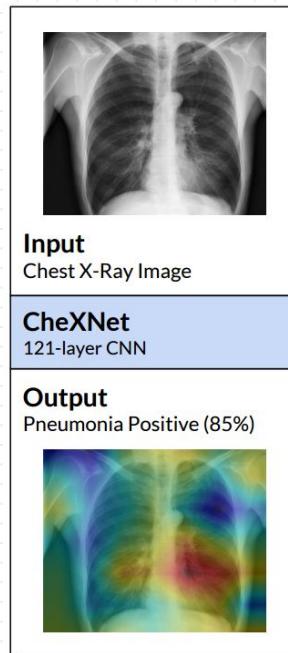
Fonte: An Augmented Reality Microscope, Google Research Blog, 2018.



Pneumonia Detection on Chest X-Rays

Pathology

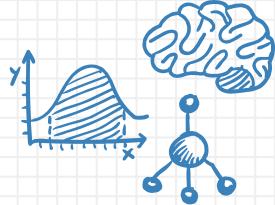
Atelectasis
Cardiomegaly
Effusion
Infiltration
Mass
Nodule
Pneumonia
Pneumothorax
Consolidation
Edema
Emphysema
Fibrosis
Pleural Thickening
Hernia



	F1 Score (95% CI)
Radiologist 1	0.383 (0.309, 0.453)
Radiologist 2	0.356 (0.282, 0.428)
Radiologist 3	0.365 (0.291, 0.435)
Radiologist 4	0.442 (0.390, 0.492)
Radiologist Avg.	0.387 (0.330, 0.442)
CheXNet	0.435 (0.387, 0.481)

Fonte: Rajpurkar, Pranav, et al. "CheXNet: Radiologist-Level Pneumonia Detection on Chest X-Rays with Deep Learning." (2017).





Tá, mas com resultados tão bacanas...
por que queremos Aprendizado Não
Supervisionado?



O que há de errado?

- ✗ Necessita de dados rotulados
 - ✗ No caso de Deep Learning, precisa de muitos mesmo!
 - ✗ Rotular dados é geralmente um processo caro e que consome tempo

- ✗ Em geral, bastante conectado com a tarefa onde foi treinado
 - ✗ Aprendizado deve ser generalizável para outros domínios
 - ✗ Temos problemas ao apresentar instâncias muito diferentes das vistas durante o treinamento



O que há de errado? (cont'd)

Unsupervised Deep Learning - Alex Graves (NeurIPS 2018)

- ✗ Se nosso objetivo é criar sistemas inteligentes que tenham sucesso em uma grande variedade de tarefas, porque não ensinamos tais tarefas diretamente?

- ✗ Alvos (rótulos) podem ser difíceis de obter
- ✗ Aprendizado Não Supervisionado “parece mais humano”
- ✗ Queremos generalização rápida para novas tarefas e situações

Fonte: Unsupervised Deep Learning Tutorial, Alex Graves and Marc'Aurelio Ranzato, NeurIPS 2018.



Machine Learning Cake



Yann Lecun

Chief Scientist of
Facebook AI Research

- **"Pure" Reinforcement Learning (cherry)**
 - ▶ The machine predicts a scalar reward given once in a while.
 - ▶ **A few bits for some samples**

- **Supervised Learning (icing)**
 - ▶ The machine predicts a category or a few numbers for each input
 - ▶ Predicting human-supplied data
 - ▶ **10→10,000 bits per sample**

- **Unsupervised/Predictive Learning (cake)**
 - ▶ The machine predicts any part of its input for any observed part.
 - ▶ Predicts future frames in videos
 - ▶ **Millions of bits per sample**



Aprendizado Não Supervisionado



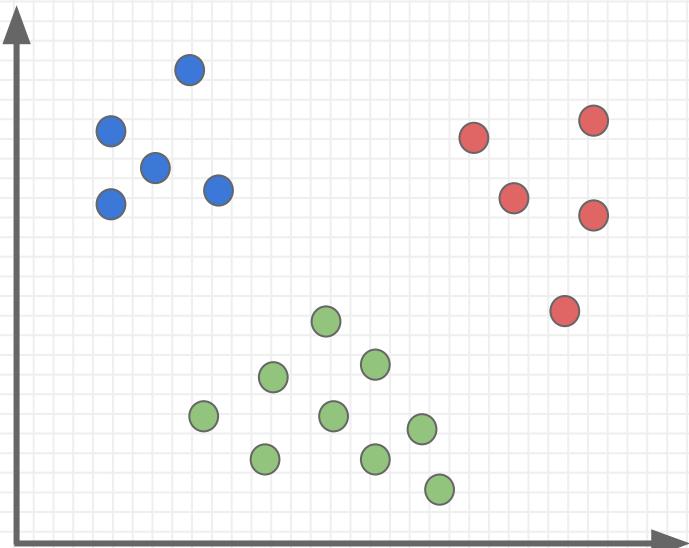
Aprendizado Não Supervisionado

- ✗ Paradigma de Machine Learning que aprende a partir de dados não rotulados;
- ✗ Busca encontrar regularidades/padrões nos dados
 - ✗ Existe uma estrutura no espaço dos dados que certos padrões ocorrem mais frequentemente do que outros
 - ✗ Quer se entender porque determinados padrões acontecem mais do que outros

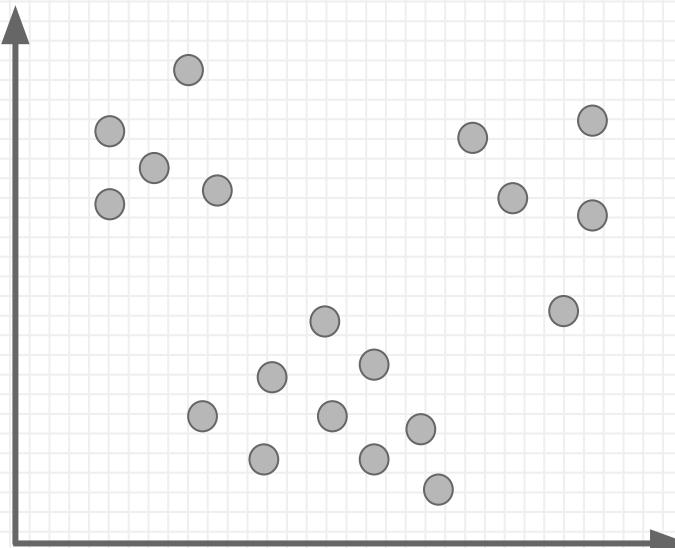
Fonte: Alpaydin, Ethem. Introduction to machine learning. MIT press, 2009.



Aprendizado Não Supervisionado



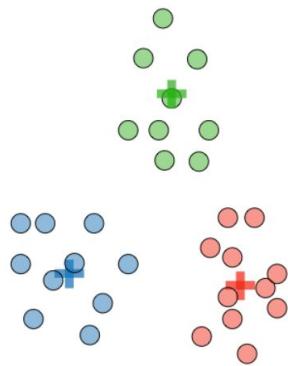
Supervisionado



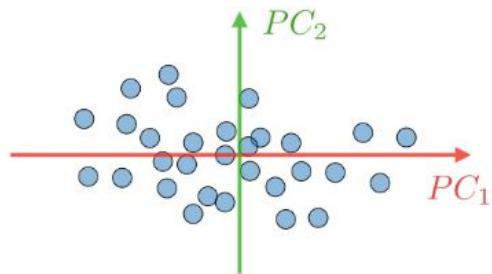
Não Supervisionado



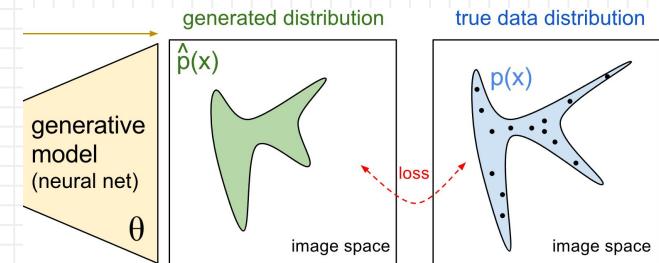
Aprendizado Não Supervisionado



Agrupamento de Dados
(Clustering)



Redução de
Dimensionalidade



Modelos Generativos



Diferenciando de outros paradigmas

Semi-supervised

- ✗ Parte dos dados são rotulados e parte dos dados não são
- ✗ Ao se utilizar pequena parte dos dados rotulados, pode-se obter resultados melhores do que apenas não supervisionado
- ✗ Além disso, “custo” reduzido quando comparado com Aprendizado Supervisionado



Diferenciando de outros paradigmas

Semi-supervised

- ✗ Exemplo: Pseudo-Labeling
 - 1. Treinamento com dados rotulados
 - 2. Classificação dos dados não rotulados
 - 3. Treinamento com todos dados



Diferenciando de outros paradigmas

Weakly supervised

- ✗ Incomplete supervision: semi-supervised pode ser considerado um caso;
- ✗ Inexact supervision: dados rotulados de forma “superficial” (*coarse*)
- ✗ Inaccurate supervision: *ground truth* não totalmente correto (e.g. rótulos incorretos)

Fonte: Zhou, Zhi-Hua. "A brief introduction to weakly supervised learning." National Science Review 5.1 (2017): 44–53.

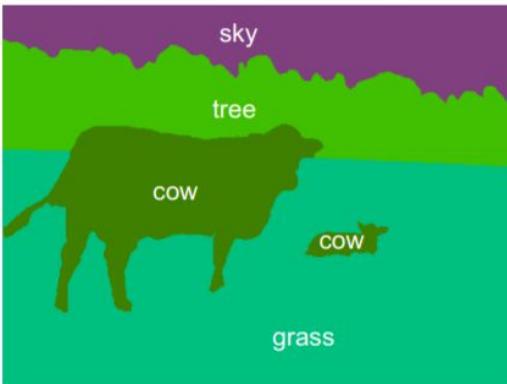


Diferenciando de outros paradigmas

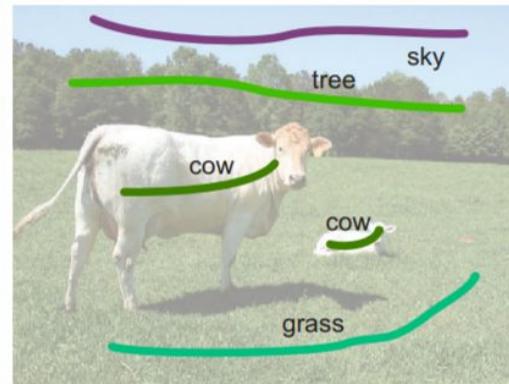
Weakly supervised



(a) image



(b) mask annotation



(c) scribble annotation

Fonte: Lin, Di, et al. "Scribblesup: Scribble-supervised convolutional networks for semantic segmentation." Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2016.



Diferenciando de outros paradigmas

Self-supervised

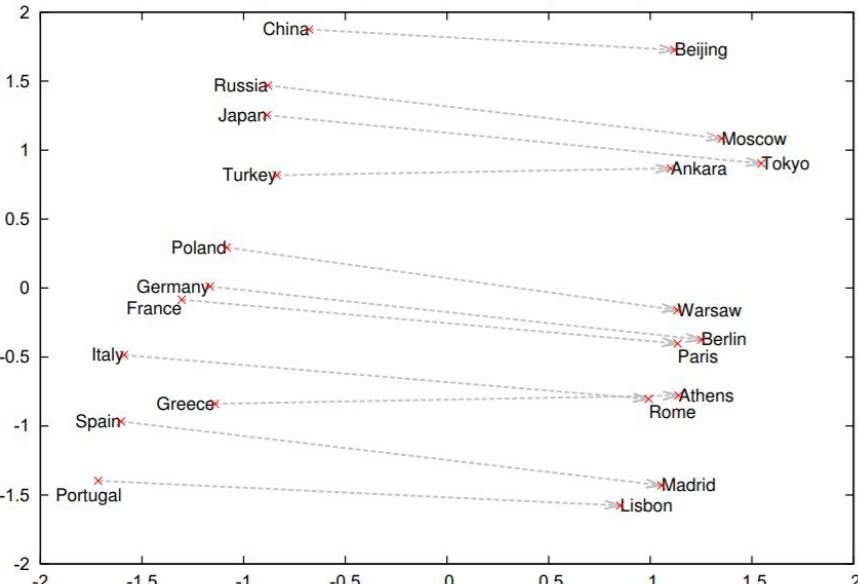
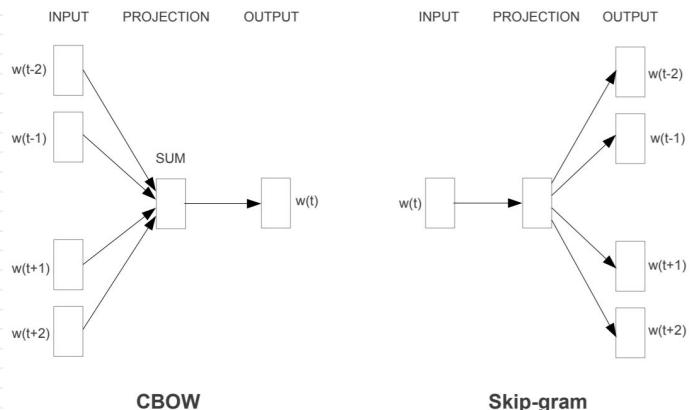
- ✗ Pode ser considerado uma forma de Aprendizado Não Supervisionado, onde os dados provém supervisão
- ✗ Em geral, treina-se o modelo para tentar “predizer os dados”
- ✗ É uma forma de Representation Learning que não necessita de dados rotulados



Diferenciando de outros paradigmas

Self-supervised

X Exemplo: Word2Vec

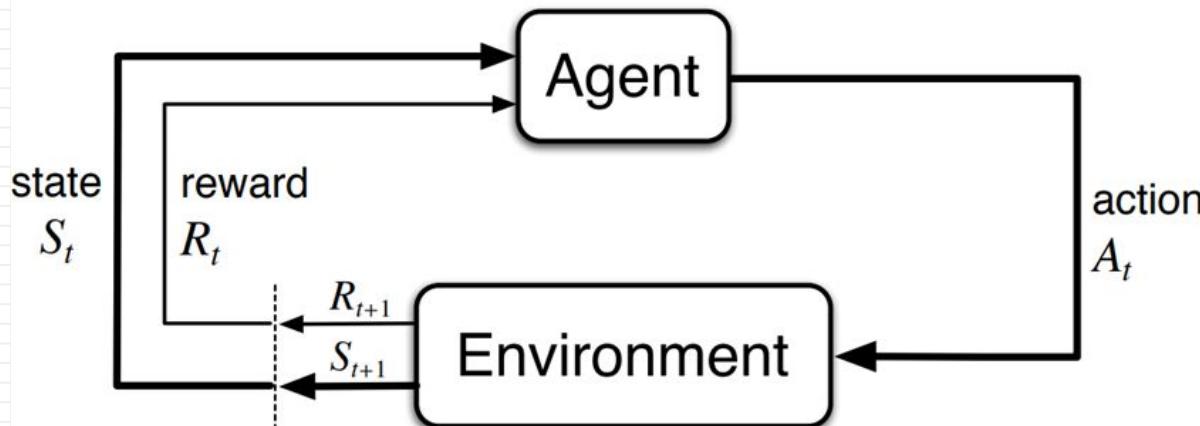


Fonte: Mikolov, Tomas, et al. "Distributed representations of words and phrases and their compositionality." Advances in neural information processing systems. 2013.



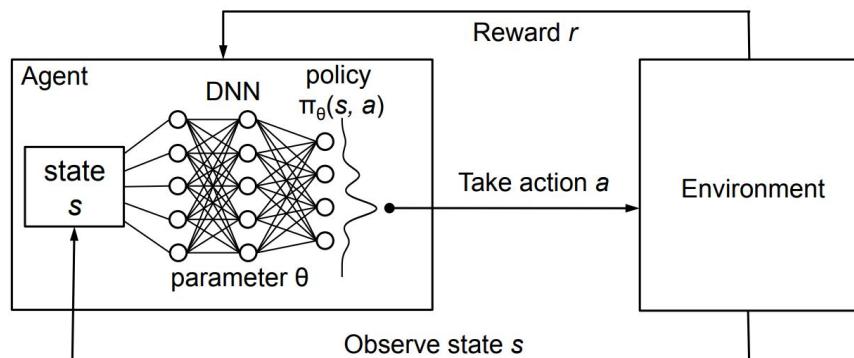
Diferenciando de outros paradigmas

Reinforcement Learning



Diferenciando de outros paradigmas

Reinforcement Learning (DQN)



Fonte: <https://www.youtube.com/watch?v=TmPfTpjtdgg>



Aprendizado Não Supervisionado

Alguns exemplos onde o paradigma pode ser aplicado



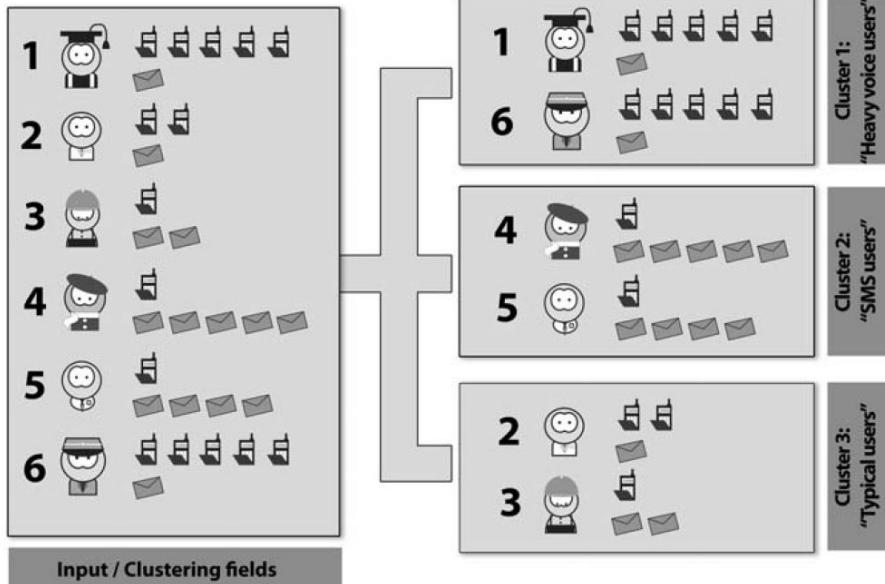
Segmentação de clientes

- ✖ Refere-se ao processo de dividir clientes em subgrupos distintos, significativos e homogêneos, com base em vários atributos e características;
- ✖ Tradicionalmente, empresas utilizam métodos de marketing baseados em dados demográficos e algumas outras informações;
- ✖ No entanto, para se obter vantagem competitiva deve-se utilizar técnicas mais adequadas para entender melhor os clientes.

Fonte: Tsipitsis, Konstantinos K., and Antonios Chorianopoulos. Data mining techniques in CRM: inside customer segmentation. John Wiley & Sons, 2011.



Segmentação de clientes



Pode ser útil para

- ✗ Melhor entendimento dos clientes
- ✗ Criação de novos produtos ou serviços
- ✗ Diferenciação no atendimento ao cliente
- ✗ Priorização de iniciativas de Marketing

Fonte: Tsipitsis, Konstantinos K., and Antonios Chorianopoulos. Data mining techniques in CRM: inside customer segmentation. John Wiley & Sons, 2011.



Detecção de anomalias

- ✗ O objetivo é identificar instâncias anormais, que sejam diferentes da maior parte das outras instâncias;
- ✗ Instâncias anômalas são conhecidas como *outliers* (também chamado de Detecção de Outliers);
- ✗ Temos também o *Novelty Detection*
 - ✗ Procura detectar dados não observados anteriormente
 - ✗ Uma das principais diferenças: tais dados são normalmente incorporados no modelo original

Fonte: Tan, Pang-Ning. Introduction to data mining. Pearson Education India, 2007.



Detecção de anomalias

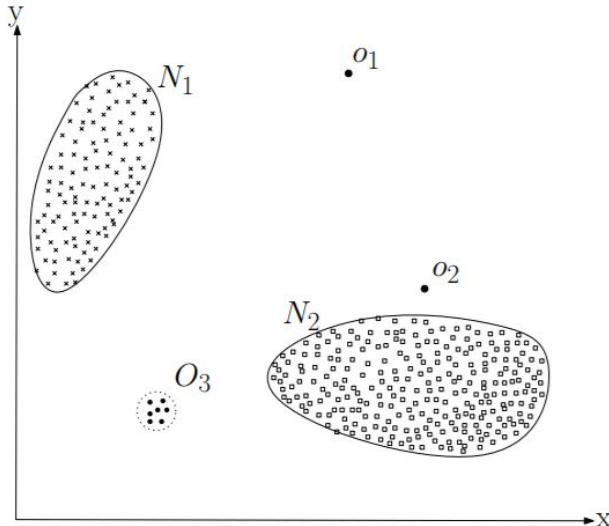


Fig. 1. A simple example of anomalies in a 2-dimensional data set.

Alguns exemplos incluem

- ✗ Detecção de fraudes em cartões de crédito
- ✗ Saúde pública
- ✗ Detecção de intrusão em sistemas de informação

Fonte: Chandola, Varun, Arindam Banerjee, and Vipin Kumar. "Anomaly detection: A survey." ACM computing surveys (CSUR) 41.3 (2009): 15.



Regras de associação

- ✗ Técnica amplamente utilizada para analisar dados transacionais, com o objetivo de encontrar regras a partir de tais dados de acordo com uma medida de interesse;
- ✗ Não apenas regras, mas associações, correlações e padrões frequentes em grupos de itens;
- ✗ As regras encontradas geralmente possuem o formato SE/ENTÃO
 - ✗ **SE:** antecedente **ENTÃO:** consequente (efeito)
 - ✗ Exemplo: “Se um cliente compra carvão, ele tem 80% de chance de comprar carne”



Regras de associação

- Exemplo clássico (*market basket transactions*)

ID da transação	Itens
1	{Bread, Milk}
2	{Bread, Diapers, Beer, Eggs}
3	{Milk, Diapers, Beer, Cola}
4	{Bread, Milk, Diapers, Beer}
5	{Bread, Milk, Diapers, Cola}

Regra possível

- $\{Diapers\} \rightarrow \{Beer\}$

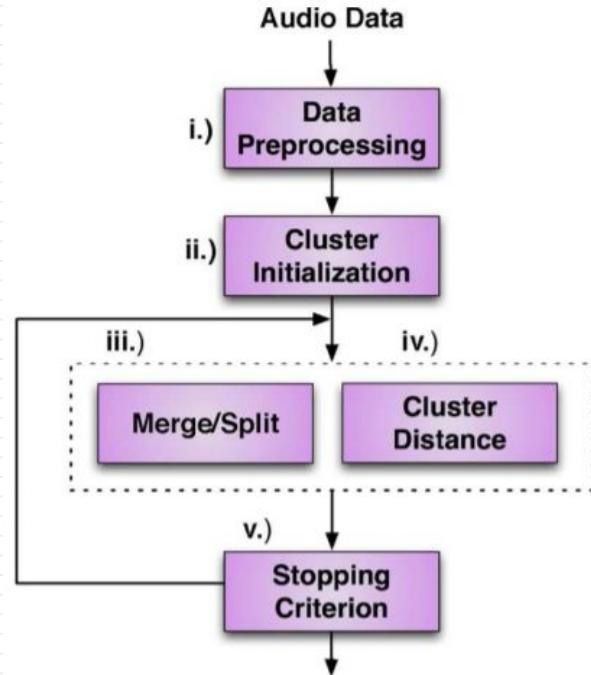
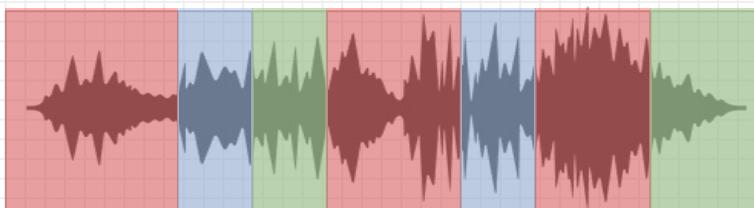
Sugere que existe forte relação entre a venda de fraldas e cerveja.

Fonte: Tan, Pang-Ning. Introduction to data mining. Pearson Education India, 2007.



Speaker Diarization

- ✗ **Quem falou quando**
- ✗ Identificação não supervisionada dos locutores de um áudio e os intervalos nos quais cada locutor está falando



Fonte: Anguera, Xavier, et al. "Speaker diarization: A review of recent research." IEEE Transactions on Audio, Speech, and Language Processing 20.2 (2012): 356-370.



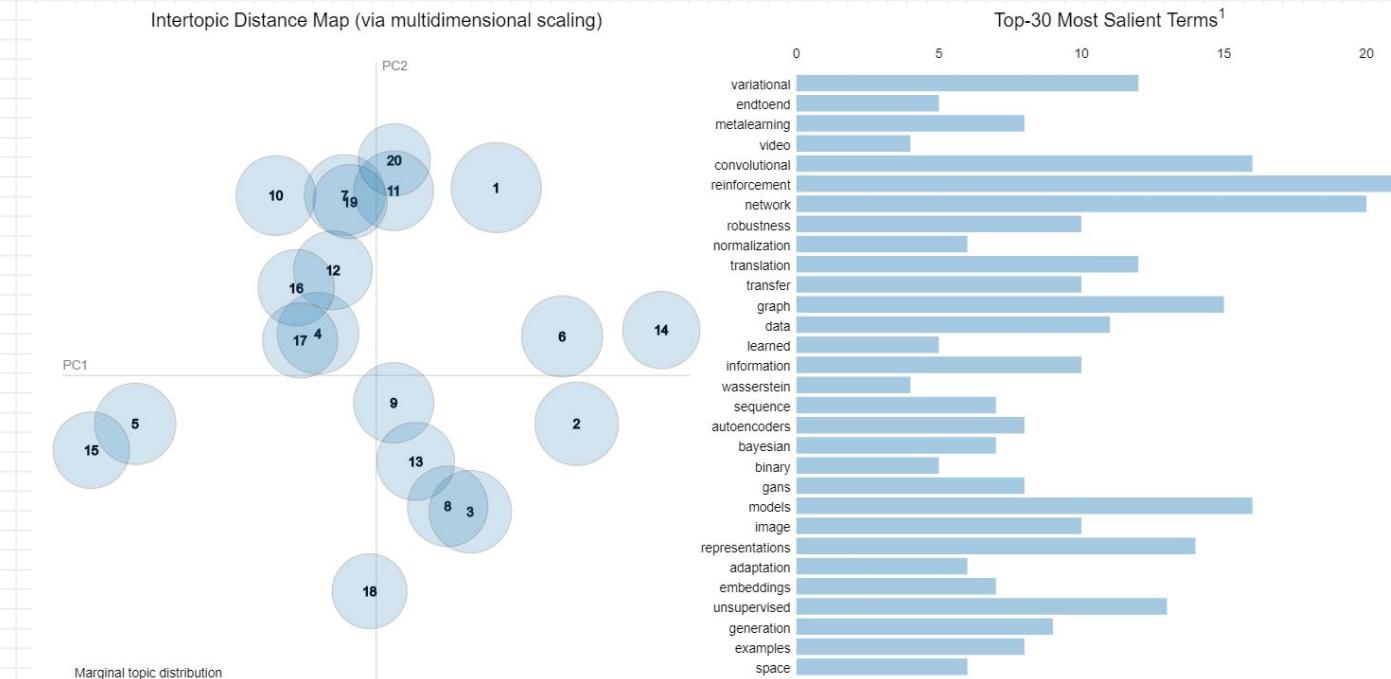
Topic Modeling

- ✗ Técnica para analisar uma grande coleção de documentos
 - ✗ Descobrir temas “escondidos” que estão na coleção
 - ✗ Rotular documentos de acordo com esses temas
 - ✗ Utilizar as anotações para organizar, resumir e buscar textos
- ✗ Um tópico é definido com base na co-ocorrência de palavras e inclui grupos de palavras que geralmente ocorrem em conjunto em diferentes documentos;
- ✗ Geralmente utilizado como uma etapa inicial antes de aplicar-se tarefas de mineração de texto.

Fonte: Barde, Bhagyashree Vyankatral, and Anant Madhavrao Bainwad. "An overview of topic modeling methods and tools." Intelligent Computing and Control Systems (ICICCS), 2017 International Conference on. IEEE, 2017.



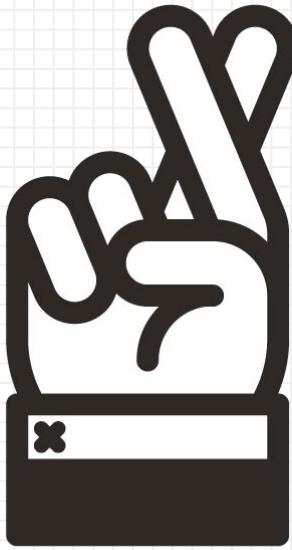
Topic Model – Exemplo



Fonte: ICLR 2019 papers



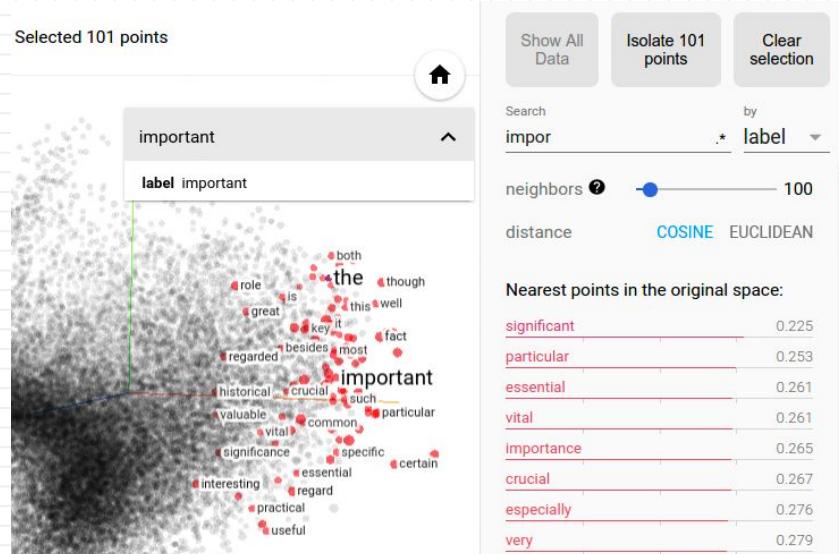
DEMO TIME



Redução de Dimensionalidade – Exemplos

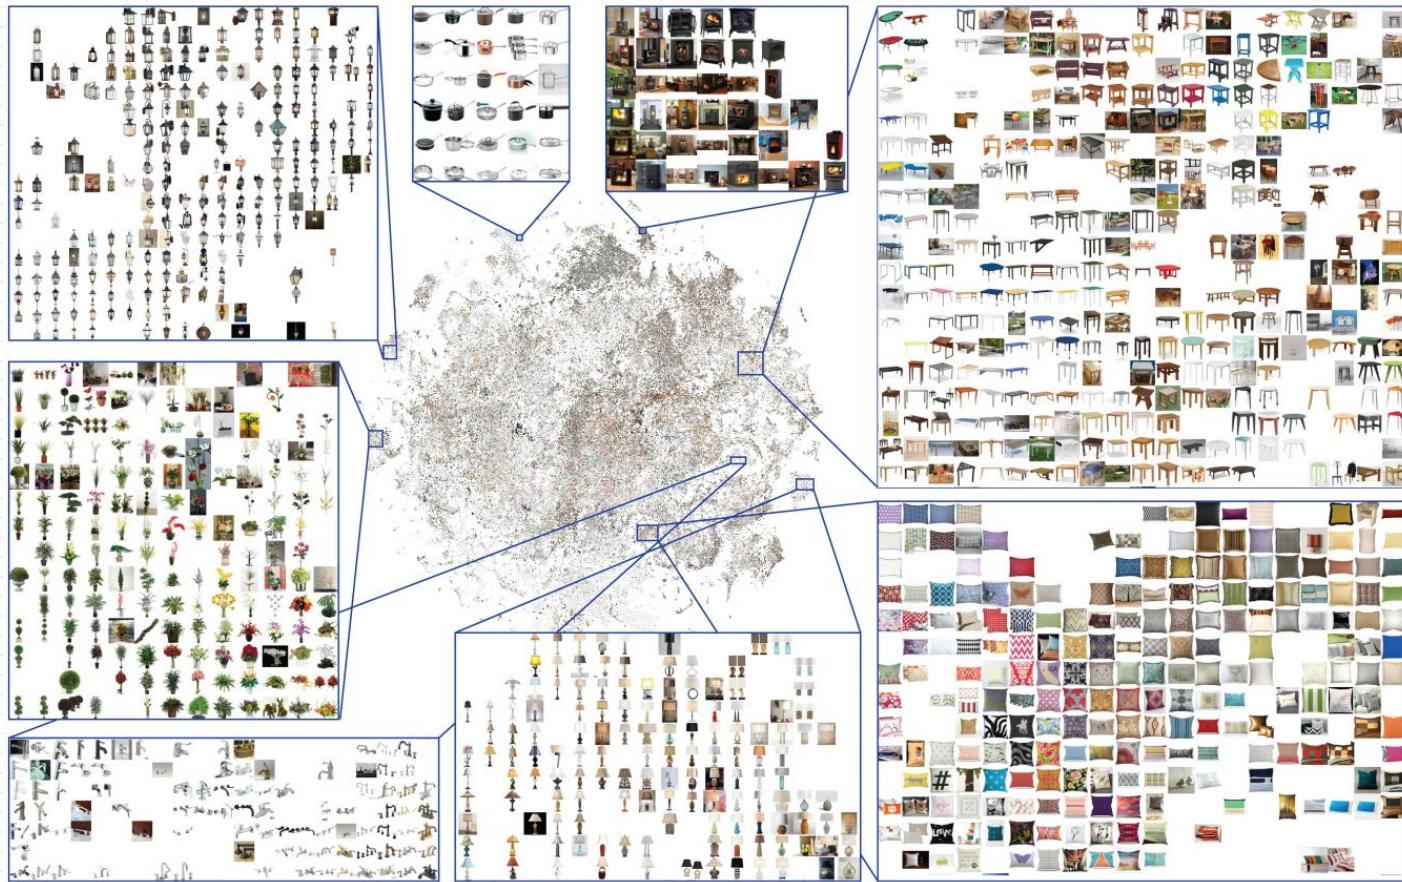


Fonte: <https://cs.stanford.edu/people/karpathy/cnnembed/>



Fonte: <https://www.tensorflow.org/guide/embedding>

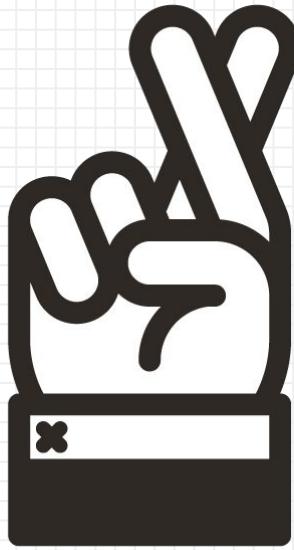




Fonte: Bell, Sean, and Kavita Bala. "Learning visual similarity for product design with convolutional neural networks." ACM Transactions on Graphics (TOG) 34.4 (2015): 98.



DEMO TIME



Aprendizado Não Supervisionado

Alguns exemplos do estado-da-arte



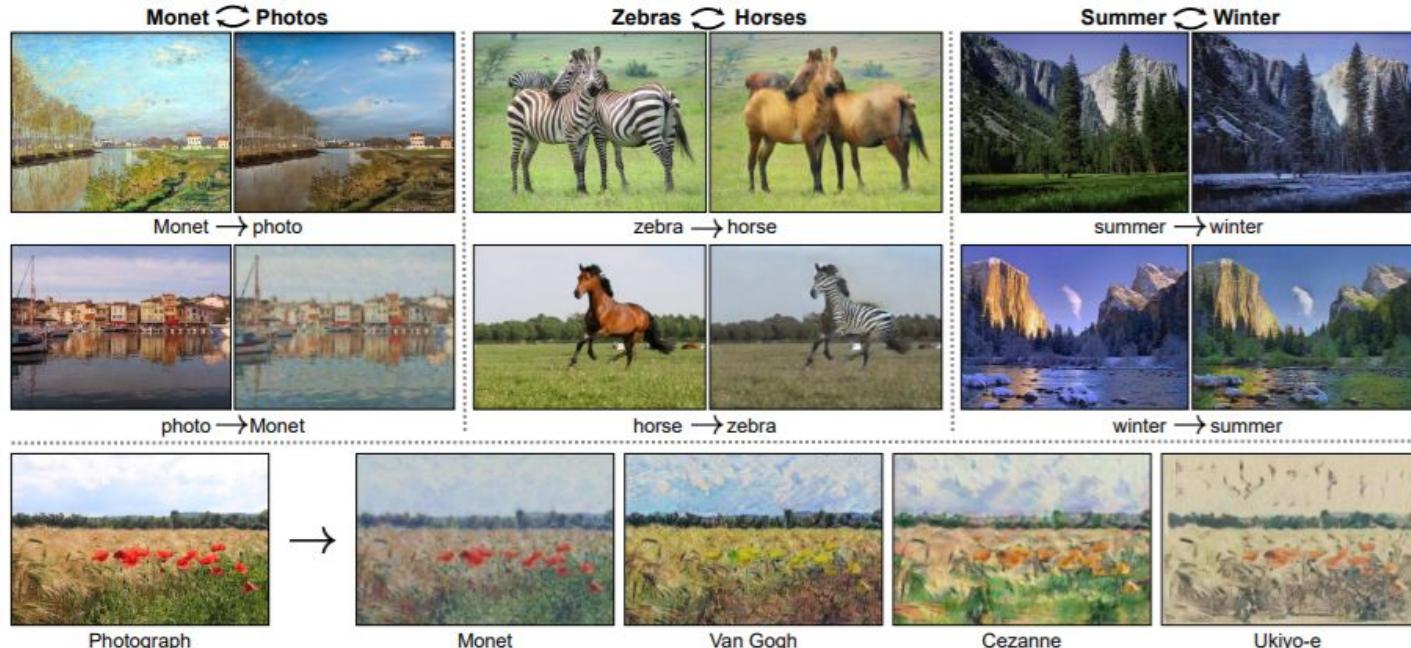
Image-to-Image Translation

- ✗ Aprender o mapeamento de uma imagem de entrada para uma imagem de saída;
- ✗ Utiliza a imagem de entrada como uma condição para a geração da imagem de saída;
- ✗ Baseado em *Generative Adversarial Networks* (GANs)
 - ✗ Veremos mais adiante na aula o que elas são!

Fonte: Isola, Phillip, et al. "Image-to-image translation with conditional adversarial networks." arXiv preprint (2017).



Image-to-Image Translation



Fonte: Zhu, Jun-Yan, et al. "Unpaired image-to-image translation using cycle-consistent adversarial networks." arXiv preprint[2017].



Video-to-Video Synthesis

- ✗ Aprender o mapeamento de um vídeo de entrada (geralmente simplificado, como uma segmentação) para um vídeo de saída foto realístico;
- ✗ Primeiro trabalho que conseguiu implementar o conceito de *image-to-image translation* para vídeos, respeitando o aspecto temporal;
- ✗ Também é baseado em GANs

Fonte: Wang, Ting-Chun, et al. "Video-to-Video Synthesis." arXiv preprint arXiv:1808.06601 (2018).



Video-to-Video Synthesis

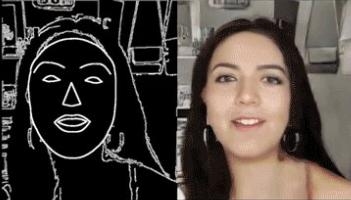


Fonte: Wang, Ting-Chun, et al. "Video-to-Video Synthesis." arXiv preprint arXiv:1808.06601 (2018).



Video-to-Video Synthesis

Edge-to-Face Results



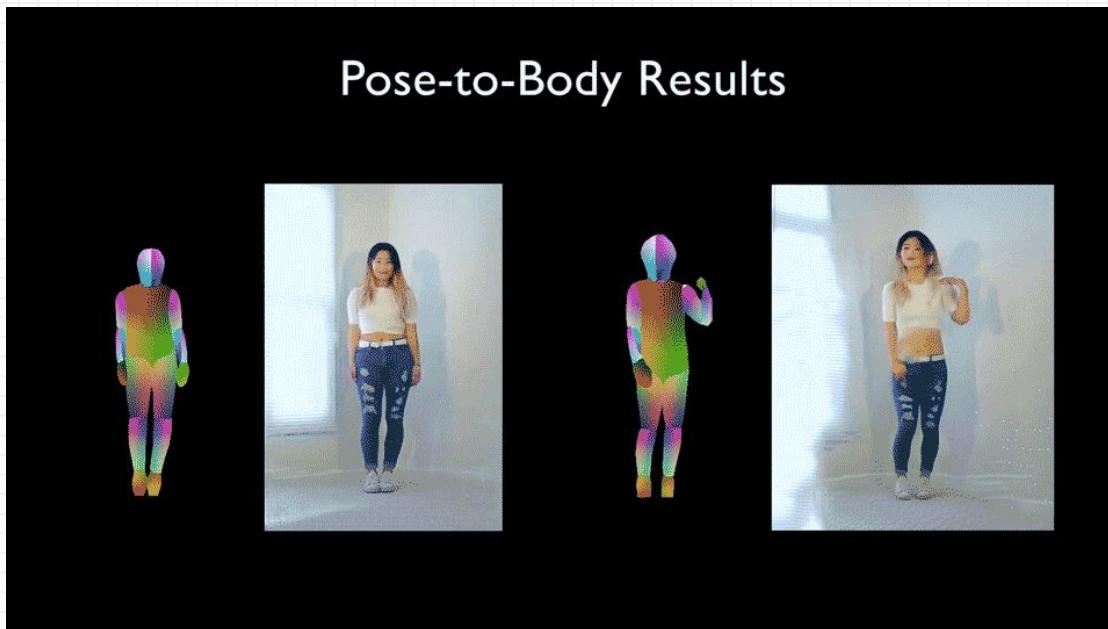
Multiple Outputs for Edge-to-Face



Fonte: Wang, Ting-Chun, et al. "Video-to-Video Synthesis." arXiv preprint arXiv:1808.06601 (2018).



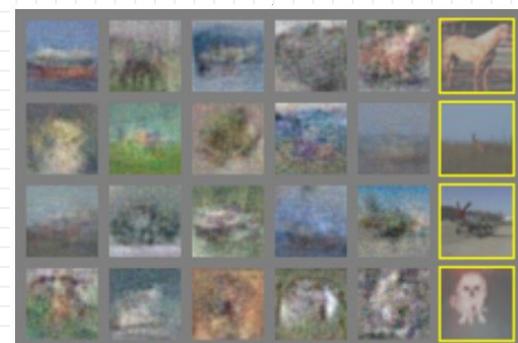
Video-to-Video Synthesis



Fonte: Wang, Ting-Chun, et al. "Video-to-Video Synthesis." arXiv preprint arXiv:1808.06601 (2018).



Image Generation (no início)



Fonte: Goodfellow, Ian, et al. "Generative adversarial nets." Advances in neural information processing systems. 2014.



Image Generation (atualmente*)



Our (256 × 256)

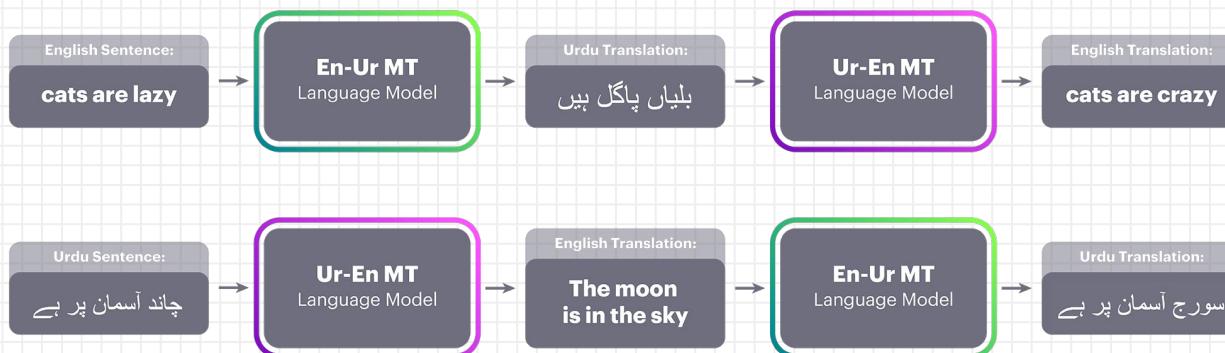
Figure 5: 1024 × 1024 images generated using the CELEBA-HQ dataset. See Appendix F for a larger set of results, and the accompanying video for latent space interpolations.

Fonte: Karras, Tero, et al. "Progressive growing of gans for improved quality, stability, and variation." arXiv preprint arXiv:1710.10196 (2017).



Unsupervised Machine Translation

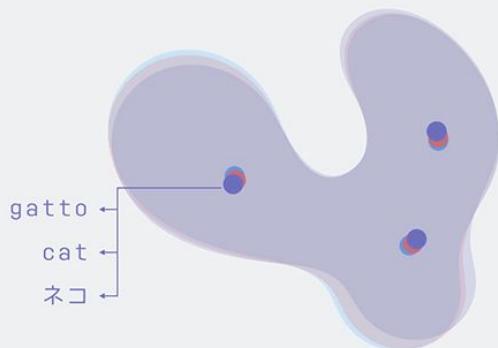
- ✗ Existem cerca de **6500** linguagens no mundo!
 - ✗ Alguns dizem ser > **7000**!
- ✗ Para a maior parte delas, não existe tradução em outros idiomas ou a quantidade de dados é muito pequena.



Fonte: Lample, Guillaume, et al. "Phrase-Based & Neural Unsupervised Machine Translation." arXiv preprint arXiv:1804.07755 (2018).



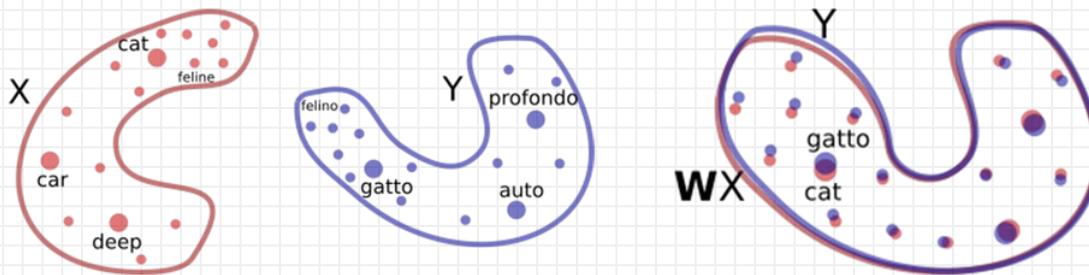
Unsupervised Machine Translation



Fonte: Lample, Guillaume, et al. "Phrase-Based & Neural Unsupervised Machine Translation." arXiv preprint arXiv:1804.07755 (2018).



Unsupervised Machine Translation



Source	Je rêve constamment d'eux, peut-être pas toutes les nuits mais plusieurs fois par semaine c'est certain.
NMT Epoch 1	I constantly dream, but not all nights but by several times it is certain.
NMT Epoch 3	I continually dream them, perhaps not all but several times per week is certain.
NMT Epoch 45	I constantly dream of them, perhaps not all nights but several times a week it's certain.
PBSMT Iter. 0	I dream of, but they constantly have all those nights but several times a week is too much."
PBSMT Iter. 1	I had dreams constantly of them, probably not all nights but several times a week it is large.
PBSMT Iter. 4	I dream constantly of them, probably not all nights but several times a week it is certain.
Reference	I constantly dream of them, perhaps not every night, but several times a week for sure.

Fonte: Lample, Guillaume, et al. "Phrase-Based & Neural Unsupervised Machine Translation." arXiv preprint arXiv:1804.07755 (2018).



Como o Aprendizado Não Supervisionado ajudou Deep Learning



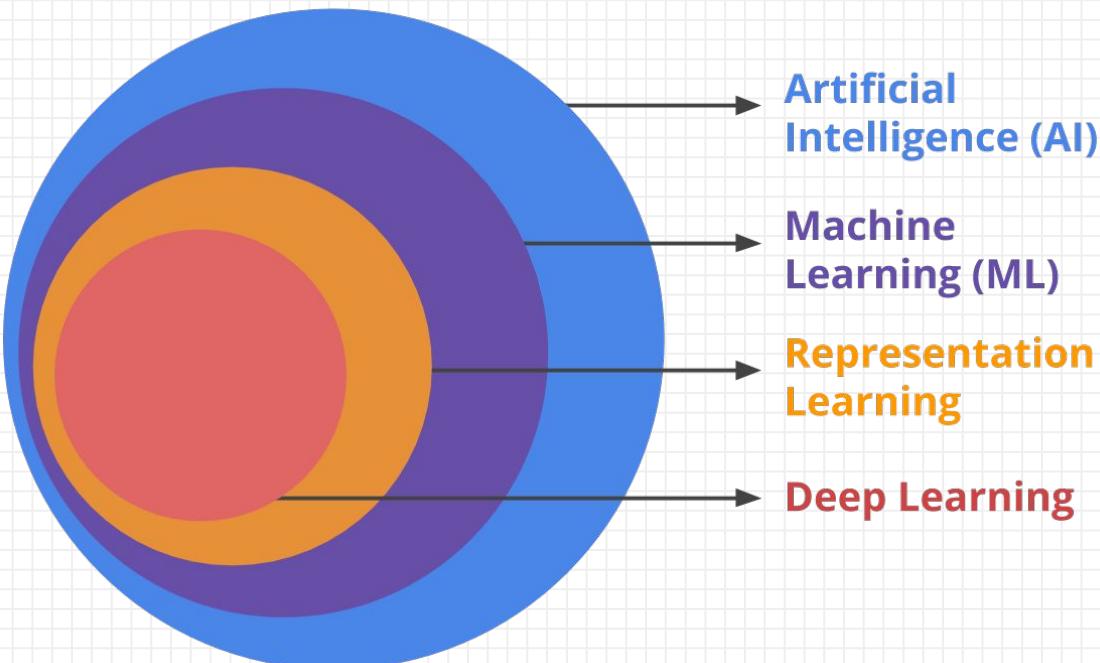
Pré-treino Não Supervisionado

- ✗ Durante alguns anos, foram efetuadas diferentes tentativas para treinar redes neurais profundas (com mais de 1 ou 2 camadas escondidas)
 - ✗ Tentativas não eram bem sucedidas (*vanishing gradient*)
- ✗ Um *breakthrough* aconteceu em 2006:
 - ✗ Aprendizado não supervisionado como pré-treino;
 - ✗ Aprendizado supervisionado para realizar *fine-tuning*
- ✗ Atualmente, pré-treino não supervisionado é praticamente não utilizado

Fonte: Erhan, Dumitru, et al. "Why does unsupervised pre-training help deep learning?." Journal of Machine Learning Research 11.Feb (2010): 625-660..



Deep Learning

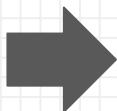


Fonte: Deep Learning (Goodfellow, Bengio, Courville)

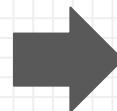


Deep Learning

“Tradicional”

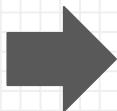


Extrator de
features
hand-crafted

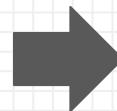


Classificador

Deep Learning



Extrator de
features treinado



Classificador



Interpretabilidade

Different **optimization objectives** show what different parts of a network are looking for.

n layer index

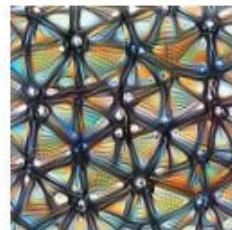
x, y spatial position

z channel index

k class index



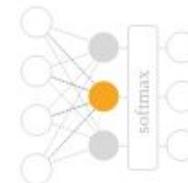
Neuron
 $\text{layer}_n[x, y, z]$



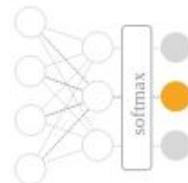
Channel
 $\text{layer}_n[:, :, z]$



Layer/DeepDream
 $\text{layer}_n[:, :, :]^2$



Class Logits
 $\text{pre_softmax}[k]$

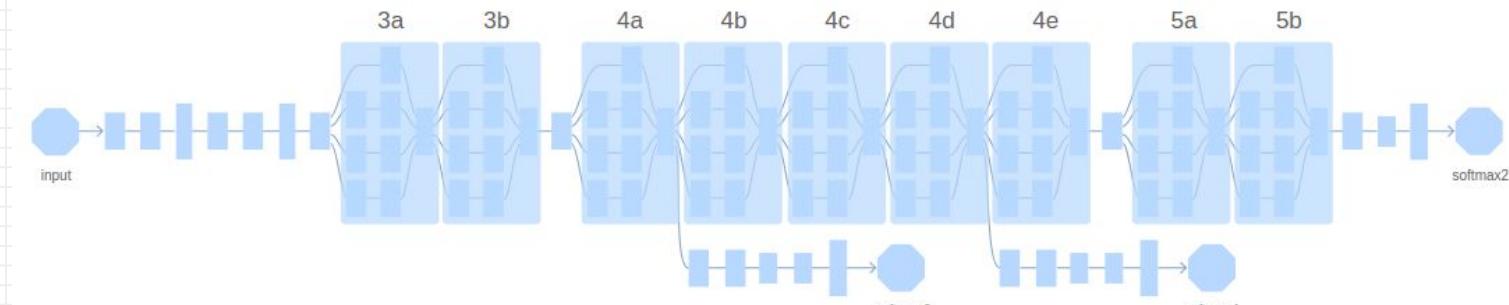


Class Probability
 $\text{softmax}[k]$

Fonte: Feature Visualization - <https://distill.pub/2017/feature-visualization/>



Interpretabilidade



Layer 4c



Palm trees



Wheels



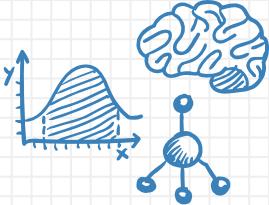
Dogs on leash



Houses

Fonte: Feature Visualization - <https://distill.pub/2017/feature-visualization/>





“Human and animal learning is largely unsupervised: we discover the structure of the world by observing it, not by being told the name of every object.”

LeCun, Yann, Yoshua Bengio, and Geoffrey Hinton. "Deep learning." *nature* 521.7553 (2015): 436.



Aprendizado Não Supervisionado



Considerações finais

- ✗ Aprendizado Não Supervisionado visa encontrar estruturas/padrões/regularidades nos dados;
- ✗ Existem mais aplicações e pesquisas relacionadas à Aprendizado Supervisionado do que Aprendizado Não Supervisionado
 - ✗ Combinação das duas abordagens possui grande potencial
- ✗ Aprendizado Não Supervisionado é muito mais do que apenas Agrupamento de Dados :)



Vamos iniciar nossa jornada!

